Университет ИТМО, факультет программной инженерии и компьютерной техники
Двухнедельная отчётная работа по «Информатике»: аннотация к статье

Дата прошедшей лекции	Номер прошедшей лекции	Название статьи/главы книги/видеолекции	Дата публикации (не старше 2022 года)	Размер статьи (от 400 слов)	Дата сдачи
10.09.2025	1	Системы счисления в древности и современности	23.05.2022	~3900	24.09.2025
24.09.2025	2	МЕТОД ПОВЫШЕНИЯ ЦЕЛОСТНОСТИ ИНФОРМАЦИИ В СИСТЕМАХ ХРАНЕНИЯ ДАННЫХ, ЗА СЧЕТ КОМБИНАЦИИ СИНДРОМНОГО И ВЕРОЯТНОСТНОГО ДЕКОДИРОВАНИЯ	07.07.2025	~3100	08.10.2025
08.10.2025	3	Применение регулярных выражений для обработки текстовых данных	**.09.2022	~2500	22.10.2025
22.10.2025	4	СРАВНИТЕЛЬНЫЙ АНАЛИЗ ФОРМАТОВ ПРОТОКОЛОВ ДЛЯ ОБРАБОТКИ ДАННЫХ В СЕНСОРНЫХ СЕТЯХ ИНТЕРНЕТА ВЕЩЕЙ	10.09.2024	~3500	5.11.2025
5.11.2025	5	Отличия разработки на VBA для MS Excel по сравнению JavaScript для Р7-Офис	02.08.2024	~1200	19.11.2025
19.11.2025	6	Об автоматическом распознавании печатного текста	24.09.2024	~4500	03.12.2025
03.12.2025	7				

Выполнил(а) _____*Крамарь М.Р.*_____, № группы __*P3113*__, оценка _____

Прямая полная ссылка на источник или сокращённая ссылка (bit.ly, tr.im и т. п.)
http://injoit.org/index.php/j1/article/view/1954/1759

Теги, ключевые слова или словосочетания (минимум три слова)
Компьютерное зрение, машинное обучение, разпознавание документов, сегментация данных, LaTeX, OCR

Перечень фактов, упомянутых в статье (минимум четыре пункта)
1. Для детекции и классификации блоков документа была обучена собственная модель на основе архитектуры YOLOv8.
2. Был создан датасет, аналогичный MNIST, содержащий 28730 изображений символов русского алфавита и знаков препинания!
3. Модель для посимвольного распознавания показала на реальных данных точность порядка 50%, что сделало подход непригодным.
4. Для распознавания формул сравнивались модели LaTeX OCR и Nougat-LaTeX-OCR, где вторая показала лучшие результаты!

Позитивные следствия и/или достоинства описанной в статье технологии (минимум три пункта)
1. Система способна корректно обрабатывать документы на русском и английском языках, а также распознавать специфические математические символы (греческий алфавит, знаки модуля, пределов и т. д.)!
2. Система значительно упрощает и ускоряет процесс создания LaTeX-документов из отсканированных изображений или PDF-файлов, экономя время студентов, исследователей и технических специалистов.
3. Ключевым преимуществом перед аналогами (вроде Mathpix) является способность системы не только распознавать текст и формулы, но также детектировать, извлекать и вставлять в итоговый документ графики и иллюстрации!!!

Негативные следствия и/или недостатки описанной в статье технологии (минимум три пункта)
1. Система корректно работает с простыми файлами, но испытывает значительные трудности с документами, имеющими многоколоночную структуру или сложные элементы форматирования.
2. Система может некорректно обрабатывать выравнивание текста, игнорировать жирный шрифт и курсив, что искажает визуальное представление и смысловые акценты в исходном документе.
3. Модель иногда допускает ошибки при обработке редких и специальных символов, а попытки улучшить распознавание формул путём дообучения модели LaTeX OCR привели к её переобучению и полной неработоспособности на новых данных(.

Ваши замечания, пожелания преподавателю *или* анекдот о программистах[1]



[1] Наличие этой графы не влияет на оценку